

Trabajo Práctico 1: Reservas de Hotel

Conclusiones finales

75.06 / 95.58 Organización de Datos - FIUBA

Ing. Rodríguez - 1°C 2023



Grupo 31 - "Datazo":

- 106203 - Kisinovsky, Diego Andrés
- 102685 - Mena Giraldo, Michael Gustavo
- 104256 - Brocca, Pablo Martín

Introducción

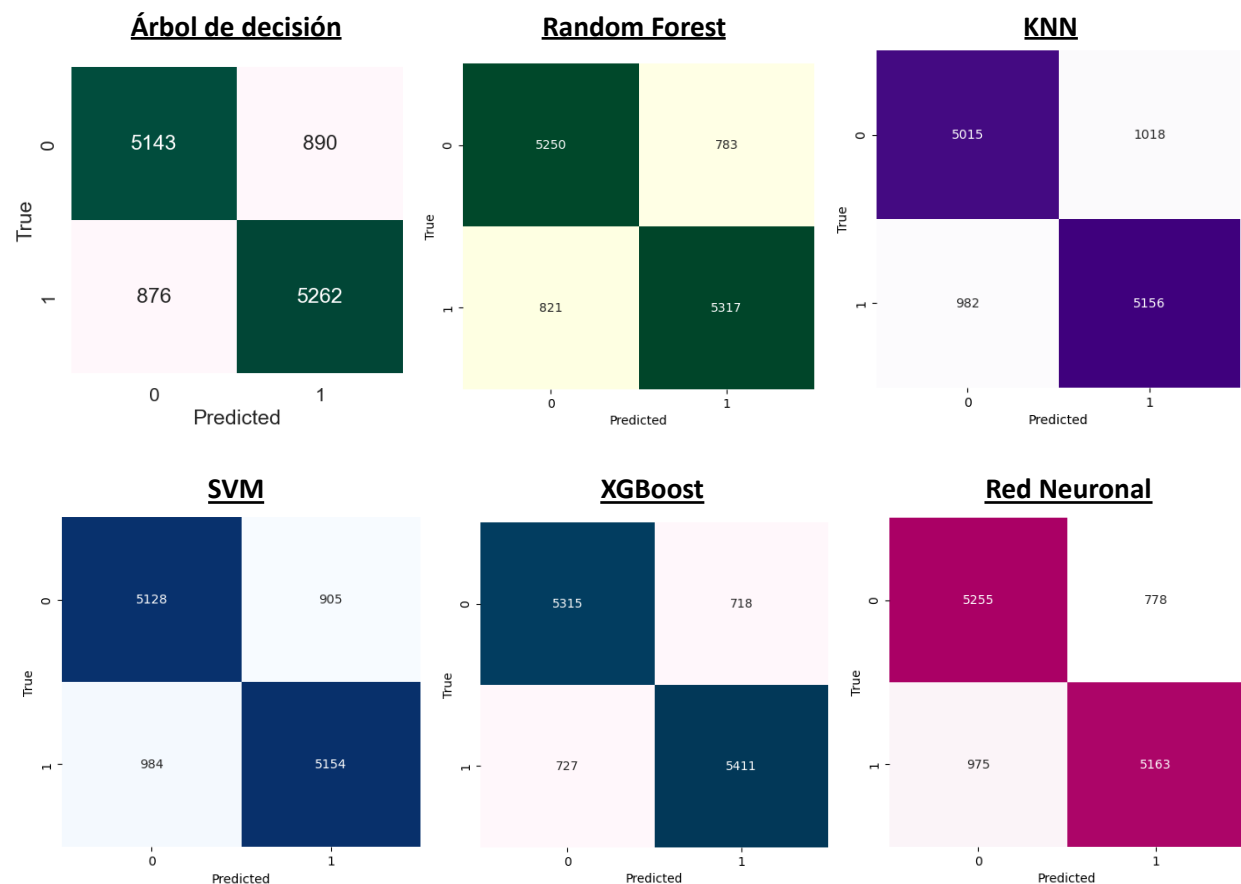
En este reporte presentamos resultados de cada modelo, hacemos observaciones respecto a lo realizado y finalmente dejamos algunas conclusiones sobre las limitaciones en la realización del trabajo práctico y lo aprendido a partir del mismo.


Observaciones generales

Volvimos a correr los modelos anteriores con algunos cambios que mejoraron la performance en general. Por un lado, aplicamos normalización Standard Scaling a los modelos que lo necesitaban. Además, volvimos a incorporar la variable categórica *country* mediante Target Encoding.

Notamos que, si bien modificar los parámetros variaba las métricas, la mayor variación la obtuvimos de los cambios en el preprocesamiento. Aunque correspondía al Checkpoint 1, fue en los Checkpoints posteriores donde aplicamos cambios más significativos en esa parte del análisis y logramos entender cómo la ingeniería de características afectaba las predicciones y el entrenamiento de cada modelo. Particularmente para modelos como SVM y Redes Neuronales, pudimos ver la gran diferencia en performance dependiendo de si los datos estaban normalizados o no.

Matrices de confusión y métricas





Métrica de Accuracy de cada modelo:

	AD	RF	KNN	SVM	XGB	RN	Voting	Stacking
Accuracy	0,8549	0,8682	0,8356	0,8447	0,8812	0,8559	0,8697	0,8838

Al observar que los modelos iban mejorando en cada Checkpoint, esperábamos que Redes Neuronales produjera mejores resultados que Stacking, que había sido nuestro mejor clasificador. No logramos hacerlo pero creemos que hubiera sido posible realizando más pruebas de las que nos permitieron nuestros recursos.

Conclusiones

Tuvimos algunas limitaciones relacionadas con los recursos que afectaron a los tiempos de ejecución y nos hicieron descartar algunas opciones. Aún probando con la aceleración por GPU de TensorFlow no pudimos superar algunos de estos obstáculos. De haber contado con más recursos, nos hubiera gustado probar Cross Validation con Grid Search para optimización de hiperparámetros en todos los modelos, y particularmente en SVM probar el kernel polinómico.

Aún así, sentimos que el trabajo cubrió todo lo aprendido en la materia, y pudimos observar cómo cada modelo se diferenciaba del anterior en parámetros y resultados, así como probar qué tan bien ajustaban al subir las predicciones a la competencia.